



GET00211 - Modelos Lineares 2

Rafael Erbisti

Instituto de Matemática e Estatística
Universidade Federal Fluminense

Aula 03

Se a fdp é escrita na forma

$$f_Y(y; \theta, \phi) = \exp\{\phi[y\theta - b(\theta)] + c(y, \phi)\} \mathcal{I}_A(y), \quad (1)$$

então

$$E(Y) = \mu = b'(\theta), \quad V(Y) = \phi^{-1} V(\mu),$$

onde a função de variância é

$$V(\mu) = \frac{d\mu}{d\theta} = b''(\theta) = \frac{\partial^2 b(\theta)}{\partial \theta^2}.$$

- Vamos provar as duas propriedades acima, para o caso contínuo. A prova para o caso discreto é análoga, substituindo-se as integrais por somatórios.



Sob certas condições de regularidade, temos que:

$$E\left[\frac{\partial \log f_Y(Y)}{\partial \theta}\right] = 0 \quad \text{e} \quad E\left[\frac{\partial^2 \log f_Y(Y)}{\partial \theta^2}\right] = -E\left[\left(\frac{\partial \log f_Y(Y)}{\partial \theta}\right)^2\right].$$

Na primeira igualdade, temos:

$$\begin{aligned} E\left[\frac{\partial \log f_Y(Y)}{\partial \theta}\right] &= \int_A \frac{\partial \log f_Y(y)}{\partial \theta} f_Y(y) dy \\ &= \int_A \frac{\partial f_Y(y)}{\partial \theta} \cdot \frac{1}{f_Y(y)} \cdot f_Y(y) dy \\ &= \int_A \frac{\partial f_Y(y)}{\partial \theta} dy \stackrel{*}{=} \frac{\partial}{\partial \theta} \int_A f_Y(y) dy \\ &= \frac{\partial}{\partial \theta}(1) = 0. \end{aligned} \tag{2}$$

* sob as condições de regularidade.



Por outro lado, note que:

$$\begin{aligned}\frac{\partial^2 \log f_Y(y)}{\partial \theta^2} &= \frac{\partial}{\partial \theta} \left(\frac{\partial \log f_Y(y)}{\partial \theta} \right) \\&= \frac{\partial}{\partial \theta} \left(\frac{1}{f_Y(y)} \cdot \frac{\partial f_Y(y)}{\partial \theta} \right) \quad (\text{pois } \frac{\partial \log f_Y}{\partial \theta} = \frac{f'_Y}{f_Y}) \\&= \frac{\frac{\partial^2 f_Y(y)}{\partial \theta^2} \cdot f_Y(y) - \left(\frac{\partial f_Y(y)}{\partial \theta} \right)^2}{f_Y(y)^2} \\&= \frac{\partial^2 f_Y(y)}{\partial \theta^2} \cdot \frac{1}{f_Y(y)} - \left(\frac{\partial f_Y(y)}{\partial \theta} \right)^2 \cdot \frac{1}{f_Y(y)^2} \\&= \frac{\partial^2 f_Y(y)}{\partial \theta^2} \cdot \frac{1}{f_Y(y)} - \left(\frac{\partial \log f_Y(y)}{\partial \theta} \right)^2\end{aligned} \tag{3}$$



Na segunda igualdade, usando o resultado em (3), temos:

$$\begin{aligned} E \left[\frac{\partial^2 \log f_Y(Y)}{\partial \theta^2} \right] &= \int_A \frac{\partial^2 \log f_Y(y)}{\partial \theta^2} f_Y(y) dy \\ &= \int_A \left\{ \frac{\partial^2 f_Y(y)}{\partial \theta^2} \cdot \frac{1}{f_Y(y)} - \left(\frac{\partial \log f_Y(y)}{\partial \theta} \right)^2 \right\} f_Y(y) dy \\ &= \int_A \frac{\partial^2 f_Y(y)}{\partial \theta^2} dy - \int_A \left(\frac{\partial \log f_Y(y)}{\partial \theta} \right)^2 f_Y(y) dy \\ &\stackrel{*}{=} \frac{\partial^2}{\partial \theta^2} \int_A f_Y(y) dy - E \left[\left(\frac{\partial \log f_Y(Y)}{\partial \theta} \right)^2 \right] \\ &= \frac{\partial^2}{\partial \theta^2} (1) - E \left[\left(\frac{\partial \log f_Y(Y)}{\partial \theta} \right)^2 \right] \\ &= - E \left[\left(\frac{\partial \log f_Y(Y)}{\partial \theta} \right)^2 \right] \end{aligned}$$



Por (2), temos

$$\begin{aligned} V\left(\frac{\partial \log f_Y(Y)}{\partial \theta}\right) &= E\left[\left(\frac{\partial \log f_Y(Y)}{\partial \theta}\right)^2\right] - \left(E\left[\frac{\partial \log f_Y(Y)}{\partial \theta}\right]\right)^2 \\ &= E\left[\left(\frac{\partial \log f_Y(Y)}{\partial \theta}\right)^2\right] = -E\left[\frac{\partial^2 \log f_Y(Y)}{\partial \theta^2}\right] \end{aligned} \quad (5)$$

Agora, para a família exponencial na forma canônica

$$f_Y(y; \theta, \phi) = \exp\{\phi[y\theta - b(\theta)] + c(y, \phi)\},$$

temos

$$\begin{aligned} \frac{\partial \log f_Y(y)}{\partial \theta} &= \phi[y - b'(\theta)] \\ \frac{\partial^2 \log f_Y(y)}{\partial \theta^2} &= -\phi b''(\theta) \end{aligned}$$



Portanto, tomando esperança

$$\begin{aligned} E\left[\frac{\partial \log f_Y(Y)}{\partial \theta}\right] &= E[\phi(Y - b'(\theta))] = 0 \\ &\Rightarrow \phi[E(Y) - b'(\theta)] = 0 \\ &\Rightarrow E(Y) = b'(\theta). \end{aligned} \tag{5}$$

Usando a identidade encontrada,

$$V\left(\frac{\partial \log f_Y(Y)}{\partial \theta}\right) = -E\left[\frac{\partial^2 \log f_Y(Y)}{\partial \theta^2}\right],$$

e substituindo as expressões da família exponencial, temos

$$V(\phi[Y - b'(\theta)]) = -E[-\phi b''(\theta)]$$

$$\phi^2 V(Y) = \phi b''(\theta)$$

$$\Rightarrow V(Y) = b''(\theta) \phi^{-1}.$$



Estrutura do MLG

Na construção de um MLG, devemos responder três perguntas fundamentais:

① Qual é a distribuição dos dados?

O vetor $\mathbf{y} = (y_1, \dots, y_n)'$, geralmente, consiste em uma amostra aleatória proveniente de uma distribuição de probabilidade da **família exponencial**.

② Quais são os preditores?

É o vetor de variáveis explicativas \mathbf{x}_i , $i = 1, \dots, n$, associado ao vetor de coeficientes $\boldsymbol{\beta} = (\beta_1, \dots, \beta_p)'$, que possivelmente influenciam à variável resposta y_i .

③ Qual é a função da média que será modelada como função linear dos preditores?

Aqui definimos a **função de ligação** $g(\mu_i)$, tal que

$$g(E[Y_i]) = \eta_i = \mathbf{x}_i' \boldsymbol{\beta},$$

onde η_i é o preditor linear para a observação i , $i = 1, \dots, n$ e $g(\cdot)$ é uma função monótona e diferenciável.



- \mathbf{y} : vetor coluna $n \times 1$ de observações

$$\mathbf{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}$$

- $\mathbf{y}' = (y_1, \dots, y_n)$: vetor linha $1 \times n$ de observações.
- x_{ij} : elemento da matriz \mathbf{X} , onde i indica a observação e j a variável explicativa

- $\mathbf{x}_i = \begin{pmatrix} x_{i1} \\ \vdots \\ x_{ip} \end{pmatrix}$: vetor coluna $p \times 1$ de variáveis explicativas para a i -ésima observação.

- $\mathbf{x}'_i = (x_{i1}, \dots, x_{ip})$: vetor linha $1 \times p$ de variáveis explicativas.

- $\boldsymbol{\beta} = \begin{pmatrix} \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}$: vetor $p \times 1$ de parâmetros.



Descrição do MLG

Um MLG possui três componentes:

① **Componente aleatório:**

Variáveis resposta Y_1, \dots, Y_n , que possuem a mesma forma de distribuição pertencente à família exponencial.

② **Componente sistemático:**

Conjunto de parâmetros β e variáveis explicativas (preditor linear)

$$\eta_i = \mathbf{x}'_i \beta, \quad \mathbf{X} = \begin{pmatrix} \mathbf{x}'_1 \\ \vdots \\ \mathbf{x}'_n \end{pmatrix} = \begin{pmatrix} x_{11} & \cdots & x_{1p} \\ \vdots & & \vdots \\ x_{n1} & \cdots & x_{np} \end{pmatrix}.$$

③ **Função de ligação:**

Uma função monótona $g(\cdot)$ tal que

$$g(\mu_i) = \eta_i = \mathbf{x}'_i \beta, \quad \text{onde } \mu_i = E(Y_i).$$



Exemplo 1: Modelo Linear Normal

Um caso particular de um MLG é o **modelo linear normal**, usualmente escrito como

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon},$$

onde $\boldsymbol{\epsilon} = (\epsilon_1, \dots, \epsilon_n)'$, $\epsilon_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$, $i = 1, \dots, n$.

Este modelo é um MLG, pois possui as três componentes:

- 1 **Componente aleatório:** temos n variáveis aleatórias independentes com distribuição normal, que pertence à família exponencial.
- 2 **Componente sistemático:** o preditor linear é dado por

$$\eta_i = \mathbf{x}_i' \boldsymbol{\beta}.$$

- 3 **Função de ligação:** a função de ligação é a identidade,

$$g(\mu_i) = \mu_i = \eta_i = \mathbf{x}_i' \boldsymbol{\beta},$$

pois $E(Y_i) = \mu_i = \eta_i$.



Exemplo 2: Taxa de mortalidade

Suponha que mortes por doenças não contagiosas sejam eventos independentes.

- O número de mortes Y por uma dada doença pode ser modelado por uma **distribuição de Poisson**:

$$f_Y(y; \lambda) = \frac{\lambda^y e^{-\lambda}}{y!}, \quad y = 0, 1, \dots,$$

onde $\lambda = E(Y)$ é o número esperado de mortes em um período de tempo específico (por exemplo, um ano).

- O parâmetro λ pode ser modelado como

$$E(Y) = \lambda = n \cdot f(\mathbf{x}'\beta),$$

onde

- n é o tamanho da população,
- $f(\mathbf{x}'\beta)$ é a taxa de mortalidade por 100 mil pessoas por ano, que pode depender de características da população (idade, sexo, histórico médico) através do componente linear $\mathbf{x}'\beta$.



Exemplo 2: Taxa de mortalidade


Número de mortes por doenças do coração e tamanho da população para grupos etários de homens da região de Hunter, New South Wales, Austrália, em 1991.

Grupo etário	nº mortes (y_i)	Pop (z_i)	Taxa (y_i/z_i) $\times 100,000$
30–34	1	17.742	5,6
35–39	5	16.554	30,2
40–44	5	16.059	31,1
45–49	12	13.083	91,7
50–54	25	10.784	231,8
55–59	38	9.645	394,0
60–64	54	10.706	504,4
65–69	65	9.933	654,4



Exemplo 2: Taxa de mortalidade

- O objetivo é modelar as mudanças na mortalidade com a idade.
- Considere variáveis aleatórias independentes Y_1, \dots, Y_n representando o número de mortes de homens que ocorrem em diversos grupos etários.
- A figura a seguir mostra como a taxa de mortalidade $y_i/n_i \times 100.000$, na escala logarítmica, cresce com a idade.



Exemplo 2: Taxa de mortalidade

- Um possível modelo para esses dados é:

$$E(Y_i) = \lambda_i = n_i e^{i\theta}, \quad Y_i \sim \text{Poisson}(\lambda_i),$$

onde $i = 1$ para o grupo 30–34 anos, $i = 2$ para 35–39 anos, \dots , $i = 8$ para 65–69 anos.

- Podemos escrevê-lo como um MLG usando a função de ligação logarítmica:

$$g(\lambda_i) = \log \lambda_i = \log n_i + i\theta$$

com preditor linear $\mathbf{x}_i' \beta$, em que

$$\mathbf{x}_i' = [\log n_i \quad i], \quad \beta = \begin{bmatrix} 1 \\ \theta \end{bmatrix}.$$



Função de Ligação

- A função de ligação relaciona os componentes sistemático e aleatório, ou seja, relaciona o preditor linear à média:

$$g(\mu_i) = \eta_i,$$

onde $g(\cdot)$ é uma função monótona e diferenciável.

- Se a função de ligação é escolhida de forma que $g(\mu_i) = \theta_i$, o preditor linear modela diretamente o parâmetro natural.
- Esta função é chamada de **função de ligação canônica**.

Distribuição	Ligação Canônica
Normal	Identidade: $\eta = \mu$
Poisson	Logarítmica: $\eta = \log \lambda$
Binomial	Logística: $\eta = \log \frac{\pi}{1-\pi}$
Gama	Recíproca: $\eta = \frac{1}{\mu}$



Função de Ligação

- Para o modelo linear normal, a função de ligação é chamada **identidade**, pois o preditor linear é igual à média. Esta função é adequada, pois η e μ podem assumir qualquer valor real.
- Para a distribuição de Poisson existe a restrição $\lambda > 0$, e uma função de ligação adequada deve respeitá-la.
 - A identidade, por exemplo, não seria apropriada, pois η pode assumir qualquer valor real dependendo dos valores estimados de $\hat{\beta}$.
- Deve-se sempre observar a adequação da função de ligação, considerando as possíveis restrições sobre a média da distribuição da variável resposta.
- Outro exemplo é a distribuição Binomial, cujo parâmetro π deve pertencer ao intervalo $(0, 1)$. Uma função de ligação apropriada deve transformar este intervalo na reta real.
- A ligação canônica é conveniente, mas não deve ser utilizada no lugar de outra ligação que apresente melhor ajuste para os dados analisados.

