



GET00211 - Modelos Lineares 2

Rafael Erbisti

Instituto de Matemática e Estatística
Universidade Federal Fluminense

Aula 04

Modelos Lineares Generalizados (MLG)

Estrutura dos MLG estudados no curso

- **Componente aleatório:** distribuição de Y na família exponencial.

$$f_Y(y; \theta, \phi) = \exp\{\phi[y\theta - b(\theta)] + c(y, \phi)\},$$

- **Componente sistemático:** preditor linear

$$\eta = \mathbf{X}\beta,$$

onde \mathbf{X} é a matriz de covariáveis e β o vetor de parâmetros.

- **Função de ligação:** relaciona a média $\mu = E(Y)$ com o preditor linear:

$$g(\mu) = \eta.$$



- Desenvolveremos agora a teoria para estimação de um MLG.
- Para obter estimativas pontuais e intervalares dos parâmetros de um MLG, vamos utilizar métodos baseados na máxima verossimilhança.
- Apesar de, em alguns casos especiais, ser possível obter a expressão matemática dos estimadores, frequentemente métodos numéricos serão necessários.
- Esses métodos são iterativos e baseados no algoritmo de Newton-Raphson.



Estimação no MLG

- Considere variáveis aleatórias independentes Y_1, \dots, Y_n que seguem as propriedades de um **Modelo Linear Generalizado**.
- Deseja-se estimar o vetor paramétrico β , relacionado a Y_i por:

$$E(Y_i) = \mu_i \quad \text{e} \quad g(\mu_i) = \mathbf{x}_i' \beta$$

- Para cada Y_i , a densidade assume a forma da **família exponencial**:

$$f_Y(y_i; \theta_i, \phi) = \exp\{\phi [y_i \theta_i - b(\theta_i)] + c(y_i, \phi)\}$$

- Nesse caso, a função de log-verossimilhança é dada por:

$$\ell_i(\theta_i, y_i) = \phi [y_i \theta_i - b(\theta_i)] + c(y_i, \phi),$$

onde $b(\cdot)$ e $c(\cdot, \cdot)$ são funções conhecidas.

- Propriedades importantes já vistas:

$$E(Y_i) = \mu_i = b'(\theta_i), \quad V(Y_i) = \frac{b''(\theta_i)}{\phi}, \quad g(\mu_i) = \mathbf{x}_i' \beta = \eta_i$$



Log-Verossimilhança e Função Escore no MLG

- A função de log-verossimilhança para todos os Y_i é:

$$\ell(\boldsymbol{\theta}; \mathbf{y}) = \sum_{i=1}^n \ell_i = \sum_{i=1}^n \left[\phi(y_i \theta_i - b(\theta_i)) + c(y_i, \phi) \right].$$

- Para obter o estimador de máxima verossimilhança de β_j , precisamos resolver:

$$U_j = \frac{\partial \ell}{\partial \beta_j} = 0,$$

onde:

$$U_j = \sum_{i=1}^n \frac{\partial \ell_i}{\partial \beta_j} = \sum_{i=1}^n \frac{\partial \ell_i}{\partial \theta_i} \cdot \frac{\partial \theta_i}{\partial \mu_i} \cdot \frac{\partial \mu_i}{\partial \beta_j}.$$

- Essa decomposição pode ser entendida como:

- 1 $\frac{\partial \ell_i}{\partial \theta_i}$: contribuição direta da densidade.
- 2 $\frac{\partial \theta_i}{\partial \mu_i}$: relação entre parâmetro canônico e média.
- 3 $\frac{\partial \mu_i}{\partial \beta_j}$: relação entre a média e os parâmetros via função de ligação.



Derivadas Intermediárias para a Função Escore

- Do termo **(1)** temos:

$$\frac{\partial \ell_i}{\partial \theta_i} = \phi(y_i - b'(\theta_i)) = \phi(y_i - \mu_i),$$

pois, $\mu_i = E(Y_i) = b'(\theta_i)$.

- Do termo **(2)** tem-se:

$$\frac{\partial \theta_i}{\partial \mu_i} = \left(\frac{\partial \mu_i}{\partial \theta_i} \right)^{-1}$$

- Como:

$$\frac{\partial \mu_i}{\partial \theta_i} = b''(\theta_i),$$

segue que:

$$\frac{\partial \theta_i}{\partial \mu_i} = \frac{1}{b''(\theta_i)} = \frac{1}{\phi V(Y_i)},$$

pois

$$V(Y_i) = \frac{b''(\theta_i)}{\phi}.$$



Função Escore e Estimação de β

- Finalmente, do termo **(3)** temos:

$$\frac{\partial \mu_i}{\partial \beta_j} = \frac{\partial \mu_i}{\partial \eta_i} \cdot \frac{\partial \eta_i}{\partial \beta_j} = \frac{\partial \mu_i}{\partial \eta_i} x_{ij},$$

onde $\eta_i = \mathbf{x}_i' \beta$.

- Logo, a **função escore** para o parâmetro β_j é dada por:

$$U_j = \sum_{i=1}^n \frac{(y_i - \mu_i)}{V(Y_i)} x_{ij} \frac{\partial \mu_i}{\partial \eta_i}.$$

- O **estimador de máxima verossimilhança** de β é obtido resolvendo:

$$\mathbf{U} = (U_1, \dots, U_p)' = \mathbf{0}.$$

- Em geral, essas equações são não lineares e devem ser resolvidas numericamente por processos iterativos, como o **método de Newton-Raphson**.



- Sabe-se que a matriz de variâncias e covariâncias dos U_j 's é dada pela matriz informação de Fisher, com elementos:

$$\mathcal{I}_{jk} = E(U_j U_k) = E\left(\frac{\partial \ell}{\partial \beta_j} \cdot \frac{\partial \ell}{\partial \beta_k}\right) = -E\left(\frac{\partial^2 \ell}{\partial \beta_j \partial \beta_k}\right)$$

- Nos modelos lineares generalizados temos:

$$\mathcal{I}_{jk} = -E\left(\sum_{i=1}^n \frac{\partial^2 \ell_i}{\partial \beta_j \partial \beta_k}\right) = E\left(\sum_{i=1}^n \frac{\partial \ell_i}{\partial \beta_j} \cdot \frac{\partial \ell_i}{\partial \beta_k}\right) = \sum_{i=1}^n E\left(\frac{\partial \ell_i}{\partial \beta_j} \cdot \frac{\partial \ell_i}{\partial \beta_k}\right)$$



- Substituindo a expressão de U_j , temos:

$$E \left(\frac{\partial \ell_i}{\partial \beta_j} \cdot \frac{\partial \ell_i}{\partial \beta_k} \right) = E \left[\frac{(Y_i - \mu_i)}{V(Y_i)} x_{ij} \frac{\partial \mu_i}{\partial \eta_i} \cdot \frac{(Y_i - \mu_i)}{V(Y_i)} x_{ik} \frac{\partial \mu_i}{\partial \eta_i} \right]$$

- Como $E[(Y_i - \mu_i)^2] = V(Y_i)$, resulta que:

$$E \left(\frac{\partial \ell_i}{\partial \beta_j} \cdot \frac{\partial \ell_i}{\partial \beta_k} \right) = x_{ij} x_{ik} \frac{\left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2}{V(Y_i)}$$

- Logo, os elementos da matriz informação de Fisher são dados por:

$$\mathcal{I}_{jk} = \sum_{i=1}^n x_{ij} x_{ik} \frac{\left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2}{V(Y_i)}$$



Matriz Informação de Fisher: Forma Matricial

- A matriz informação de Fisher pode ser escrita de forma matricial como:

$$\mathcal{I} = \mathbf{X}'\mathbf{W}\mathbf{X}$$

onde \mathbf{X} é a matriz de covariáveis $n \times p$ e \mathbf{W} é uma matriz diagonal $n \times n$ com elementos

$$w_{ii} = \frac{\left(\frac{\partial \mu_i}{\partial \eta_i}\right)^2}{V(Y_i)}.$$

- Essa representação é fundamental para o cálculo iterativo dos estimadores de máxima verossimilhança, como no algoritmo IRLS (Iteratively Reweighted Least Squares).



Método de Newton-Raphson

- O método de Newton-Raphson é um algoritmo iterativo utilizado para encontrar uma solução numérica da equação

$$f(x) = 0.$$

- O objetivo é encontrar o valor de x no qual a função f corta o eixo x .
- A cada iteração, o método aproxima a solução usando a derivada da função:

$$x^{(m+1)} = x^{(m)} - \frac{f(x^{(m)})}{f'(x^{(m)})}.$$




Figure: Método de Newton-Raphson para encontrar a solução de $f(x) = 0$.



Método de Newton-Raphson para EMV

- Consideremos o estimador de máxima verossimilhança (EMV) de um parâmetro qualquer ψ . A função de interesse é a **função score**:

$$U = \frac{\partial \ell(\psi; y)}{\partial \psi}$$

- O objetivo é encontrar ψ tal que $U = 0$.
- O método de Newton-Raphson fornece a iteração:

$$\hat{\psi}^{(m)} = \hat{\psi}^{(m-1)} - \frac{U^{(m-1)}}{U'^{(m-1)}}$$

- Para a estimação por máxima verossimilhança, é comum aproximar U' pelo seu valor esperado $E(U')$.
- Como $\mathcal{I} = E(-U')$, a atualização iterativa, chamada de **método do score**, é:

$$\hat{\psi}^{(m)} = \hat{\psi}^{(m-1)} + \frac{U^{(m-1)}}{\mathcal{I}^{(m-1)}} \quad (1)$$

- Essa abordagem é equivalente ao Newton-Raphson, mas usando a informação esperada em vez da derivada observada do score.



- Voltando ao problema de estimação por máxima verossimilhança no MLG.
- Para obter numericamente o EMV do vetor de parâmetros β , vamos utilizar o método do escore, ou seja, vamos encontrar a solução da equação:

$$\mathbf{U} = \mathbf{0}$$

- Os elementos do vetor \mathbf{U} são dados por:

$$U_j = \sum_{i=1}^n \frac{(y_i - \mu_i)}{V(Y_i)} x_{ij} \frac{\partial \mu_i}{\partial \eta_i}, \quad j = 1, \dots, p$$



- Para tanto, é preciso escrever a equação (1) de forma matricial:

$$\hat{\beta}^{(m)} = \hat{\beta}^{(m-1)} + [\mathcal{I}^{(m-1)}]^{-1} \mathbf{U}^{(m-1)} \quad (2)$$

onde

- $\hat{\beta}^{(m)}$ é o vetor de estimativas dos parâmetros β_1, \dots, β_p na m -ésima iteração.
- $\mathbf{U}^{(m-1)}$ é o vetor dos elementos dados do vetor escore, todos avaliados em $\hat{\beta}^{(m-1)}$.
- $\mathcal{I}^{(m-1)}$ é a matriz informação de Fisher, com elementos \mathcal{I}_{jk} .



Método do Escore no MLG

- Multiplicando ambos os lados de (2) por $\mathcal{I}^{(m-1)}$, obtemos:

$$\mathcal{I}^{(m-1)} \hat{\beta}^{(m)} = \mathcal{I}^{(m-1)} \hat{\beta}^{(m-1)} + \mathbf{U}^{(m-1)}$$

- O lado direito desta equação é dado pelo vetor com elementos:

$$\sum_{k=1}^p \sum_{i=1}^n x_{ij} x_{ik} V(Y_i) \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2 \hat{\beta}_k^{(m-1)} + \sum_{i=1}^n \frac{y_i - \mu_i}{V(Y_i)} x_{ij} \frac{\partial \mu_i}{\partial \eta_i}$$

todos avaliados em $\hat{\beta}^{(m-1)}$.

- Dessa forma, o lado direito da equação pode ser escrito matricialmente como:

$$\mathbf{X}'\mathbf{W}\mathbf{z}$$

onde o vetor \mathbf{z} tem elementos:

$$z_i = \sum_{k=1}^p x_{ik} \hat{\beta}_k^{(m-1)} + (y_i - \mu_i) \frac{\partial \eta_i}{\partial \mu_i}, \quad i = 1, \dots, n$$

com μ_i e $\frac{\partial \eta_i}{\partial \mu_i}$ avaliados em $\hat{\beta}^{(m-1)}$.



- Logo, as equações iterativas para o método do escore podem ser escritas como:

$$\mathbf{X}'\mathbf{W}\mathbf{X}\hat{\beta}^{(m)} = \mathbf{X}'\mathbf{W}\mathbf{z}$$

que têm a mesma forma das equações de **mínimos quadrados ponderados**, porém sendo resolvidas **iterativamente**.

- Esta última equação pode ser resolvida utilizando algum pacote estatístico que inclua a abordagem de MLG, tais como R, Python e SPSS.



Algoritmo do Método Numérico do Escore

① Definir valor inicial para β , ex.: $\beta^{(0)} = \mathbf{0}$.

② Encontrar $\mathbf{W}^{(m)}$ e $\mathbf{z}^{(m)}$.

③ Calcular $\hat{\beta}^{(m+1)}$ resolvendo:

$$\mathbf{X}'\mathbf{W}^{(m)}\mathbf{X}\hat{\beta}^{(m+1)} = \mathbf{X}'\mathbf{W}^{(m)}\mathbf{z}^{(m)}$$

④ Comparar $\hat{\beta}^{(m)}$ com $\hat{\beta}^{(m+1)}$:

$$\|\hat{\beta}^{(m)} - \hat{\beta}^{(m+1)}\| \leq \delta$$

⑤ Se o resultado da comparação for verdadeiro, o método **convergiu**. Caso contrário, incrementar m e voltar ao Passo 2.

