



GET00211 - Modelos Lineares 2

Rafael Erbisti

Instituto de Matemática e Estatística
Universidade Federal Fluminense

Aula 05

- Geralmente, um procedimento estatístico envolve três passos:
 - ① Especificação do modelo
 - ② Estimação dos parâmetros
 - ③ Inferência (“propriamente dita”): teste de hipóteses, intervalos de confiança, adequação do modelo etc.
- Hoje, iniciaremos o **passo 3**.
- Para realizar **inferência** é necessário conhecer a **distribuição amostral** dos estimadores e das estatísticas de qualidade de ajuste.



- No caso Normal, sabe-se que as **distribuições amostrais** podem ser determinadas exatamente.
- Para outras distribuições, é preciso basear-se em **resultados assintóticos** para grandes amostras, com base no **Teorema Central do Limite**.
- Esses resultados requerem atenção e a verificação de certas condições de regularidade.
- Para amostras independentes de variáveis com distribuição na família exponencial e, em particular, para os Modelos Lineares Generalizados, essas condições são satisfeitas.



- A ideia é que, sob certas condições, se S é uma **estatística de interesse**, então, para amostras grandes, tem-se assintoticamente que:

$$\frac{S - E(S)}{\sqrt{V(S)}} \dot{\sim} N(0, 1)$$

Ou, de forma equivalente:

$$\frac{[S - E(S)]^2}{V(S)} \dot{\sim} \chi^2(1)$$

- Assumindo que \mathbf{S} é um **vetor de estatísticas de interesse** de dimensão p , com:
 - $E(\mathbf{S})$ a **esperança** de \mathbf{S} ,
 - \mathbf{V} a **matriz de covariâncias** de \mathbf{S} .

Então, assintoticamente:

$$Q = [\mathbf{S} - E(\mathbf{S})]' \mathbf{V}^{-1} [\mathbf{S} - E(\mathbf{S})] \dot{\sim} \chi^2(p)$$



Exemplo: médias da Exponencial

- Sejam p variáveis aleatórias independentes: $X_1, \dots, X_p \sim \text{Exp}(\lambda)$, com médias $E(X_j) = \frac{1}{\lambda}$ e variâncias $V(X_j) = \frac{1}{\lambda^2}$, para $j = 1, \dots, p$.
- Dada amostras de tamanho n , as médias amostrais são:

$$S_j = \bar{X}_j = \frac{1}{n} \sum_{i=1}^n X_{ji}, \quad j = 1, \dots, p.$$

- Pelo Teorema Central do Limite, para n grande:

$$\bar{X}_j \sim N\left(\frac{1}{\lambda}, \frac{1}{n\lambda^2}\right)$$

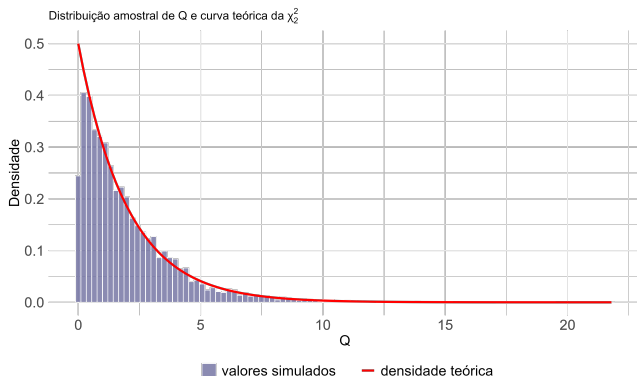
- Como as variáveis são independentes, a matriz de covariância teórica das médias amostrais é:

$$V = \frac{1}{n\lambda^2} \begin{pmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{pmatrix} = \frac{1}{n\lambda^2} \mathbf{I}_p$$



Exemplo: médias da Exponencial

- Supondo $\lambda = 1$
- Número de estatísticas: $p = 2$
- Tamanho da amostra: $n = 60$ (suficiente para o TCL)
- Número de simulações: 5000



Código R disponível [AQUI](#).



Distribuição Amostral para Estatística Escore

- Já vimos que a estatística escore é dada por:

$$U_j = \frac{\partial \ell}{\partial \beta_j}, \quad j = 1, \dots, p$$

- Além disso, a esperança do escore é zero:

$$E(U_j) = 0.$$

- A matriz de covariâncias da estatística escore é a [matriz informação de Fisher](#), dada por

$$\mathcal{I} = E(\mathbf{U}\mathbf{U}')$$

com elementos

$$\mathcal{I}_{jk} = E(U_j U_k).$$



Portanto, para grandes amostras, pelo Teorema Central do Limite:

- Caso de um único parâmetro β :

$$\frac{U}{\sqrt{\mathcal{I}}} \sim N(0, 1) \quad \text{ou, equivalentemente,} \quad \frac{U^2}{\mathcal{I}} \sim \chi^2(1)$$

- Caso de vetor de parâmetros β de dimensão $p \times 1$:

$$\mathbf{U} = (U_1, \dots, U_p)' \sim N_p(\mathbf{0}, \mathcal{I})$$

e a estatística quadrática Q é dada por

$$\mathbf{U}'\mathcal{I}^{-1}\mathbf{U} \sim \chi_p^2$$



Aproximação por série de Taylor: Conceito Básico

A série de Taylor **aproxima uma função $f(x)$ usando um polinômio** em torno de um ponto a :

$$f(x) = f(a) + f'(a)(x - a) + \frac{f''(a)}{2!}(x - a)^2 + \frac{f^{(3)}(a)}{3!}(x - a)^3 + \dots$$

- $f(a) \rightarrow$ valor da função no ponto a
- $f'(a), f''(a), \dots \rightarrow$ derivadas no ponto a
- $(x - a) \rightarrow$ distância até o ponto de expansão
- $n! \rightarrow$ fatorial que divide cada termo

Se $a = 0$, chamamos de **série de Maclaurin** (caso particular da série de Taylor).



Aproximação por série de Taylor: Exemplo

Passo 1: Derivadas

$$f(x) = e^x, \quad f'(x) = e^x, \quad f''(x) = e^x, \quad f^{(n)}(x) = e^x$$

No ponto $a = 0$:

$$f^{(n)}(0) = e^0 = 1$$

Passo 2: Montar a série

$$e^x = 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \frac{x^4}{4!} + \dots$$

Passo 3: Aproximação numérica

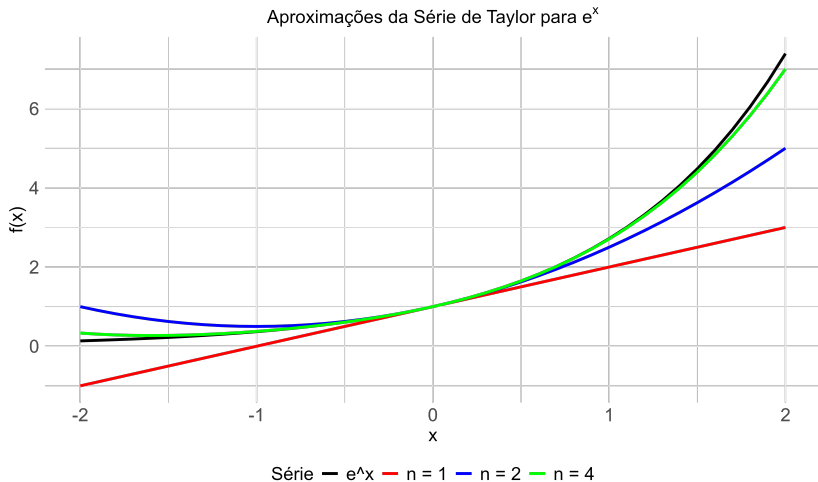
Para $x = 1$:

$$e^1 \approx 1 + 1 + \frac{1}{2} + \frac{1}{6} + \frac{1}{24} = 2,7084$$

Valor real: $e \approx 2,7183$. Com apenas quatro termos, já temos um bom resultado.



Aproximação por série de Taylor: Exemplo



Distribuição Amostral para o EMV

- Suponha que a log-verossimilhança possua apenas um máximo $\hat{\beta}$ e que esse valor estimado esteja próximo de β .
- A **aproximação de primeira ordem da expansão de Taylor** para o vetor de escores $\mathbf{U}(\beta)$ em torno de $\hat{\beta}$ é dada por:

$$\mathbf{U}(\beta) \approx \mathbf{U}(\hat{\beta}) + \mathbf{H}(\hat{\beta}) (\beta - \hat{\beta})$$

onde $\mathbf{H}(\hat{\beta})$ denota a matriz da segunda derivada da log-verossimilhança avaliada em $\hat{\beta}$.

- Se aproximarmos a matriz Hessiana em $\hat{\beta}$ pela sua esperança, temos que $\mathbf{H}(\hat{\beta}) \approx E[\mathbf{H}(\hat{\beta})] = -\mathbf{I}$, então a **expansão de Taylor do vetor escore** se torna:

$$\mathbf{U}(\beta) \approx \mathbf{U}(\hat{\beta}) - \mathbf{I}(\beta - \hat{\beta})$$

- Como $\mathbf{U}(\hat{\beta}) = \mathbf{0}$, temos:

$$\hat{\beta} - \beta \approx \mathbf{I}^{-1} \mathbf{U}(\beta)$$

dado que \mathbf{I} é não singular.



- Se a matriz informação de Fisher \mathcal{I} for considerada constante, temos:

$$E(\hat{\beta} - \beta) = \mathcal{I}^{-1} E(\mathbf{U}) = \mathbf{0}$$

então $\hat{\beta}$ é um **estimador assintoticamente não viesado** de β .

- A matriz de covariâncias assintótica de $\hat{\beta}$ é:

$$\begin{aligned} V(\hat{\beta}) &= E[(\hat{\beta} - \beta)(\hat{\beta} - \beta)'] \\ &= E[\mathcal{I}^{-1} \mathbf{U} \mathbf{U}' \mathcal{I}^{-1}] \\ &= \mathcal{I}^{-1} E[\mathbf{U} \mathbf{U}'] \mathcal{I}^{-1} \\ &= \mathcal{I}^{-1} \end{aligned}$$



Distribuição Amostral para o EMV

- Para amostras grandes, a estatística quadrática

$$(\hat{\beta} - \beta)' \mathcal{I} (\hat{\beta} - \beta) \sim \chi_p^2$$

é conhecida como **Estatística de Wald**.

- Para o caso de um único parâmetro ($p = 1$), o estimador EMV tem distribuição aproximadamente normal:

$$\hat{\beta} \sim N(\beta, \mathcal{I}^{-1})$$

- Se a variável resposta em um Modelo Linear Generalizado for **normal**, então os resultados acima são **exatos**, e não apenas assintóticos.



Intervalos de Confiança para EMV

- A **distribuição amostral assintótica** do EMV de β é: $\hat{\beta} \sim N_p(\beta, \mathcal{I}^{-1})$.
- O **erro padrão** da estimativa $\hat{\beta}_j$ é dado por:

$$SE(\hat{\beta}_j) = \sqrt{v_{jj}}$$

onde v_{jj} é o j -ésimo elemento da diagonal da matriz \mathcal{I}^{-1} .

- **Intervalos de confiança** individuais para os parâmetros:

$$\hat{\beta}_j \pm z_{1-\alpha/2} SE(\hat{\beta}_j)$$

- A correlação entre dois estimadores $\hat{\beta}_j$ e $\hat{\beta}_k$ pode ser calculada como:

$$\text{corr}(\hat{\beta}_j, \hat{\beta}_k) = \frac{v_{jk}}{\sqrt{v_{jj} v_{kk}}}$$

- **Observação:** a matriz de informação depende de β . Em aplicações práticas, substituímos β por $\hat{\beta}$.



Exemplo 1: Sejam Y_1, \dots, Y_n variáveis iid com $Y_i \sim N(\mu, \sigma^2)$, com σ^2 conhecido.

- a Obtenha o EMV para μ .
- b Determine a distribuição amostral da estatística escore e verifique que o resultado é exato.

Exemplo 2: Seja $Y \sim \text{Bin}(n, \pi)$. Obtenha a estatística escore e sua distribuição amostral aproximada.



Sob o paradigma Bayesiano, como seria o processo de inferência?

