



# GET00211 - Modelos Lineares 2

Rafael Erbisti

Instituto de Matemática e Estatística  
Universidade Federal Fluminense

Aula 07

- A análise de resíduos facilita a investigação de aspectos específicos do modelo.
- Detecta violações de pressupostos (por exemplo: estrutura de variância no modelo Normal).
- Identifica *outliers* e pontos influentes
- E guia ações corretivas: transformação de variáveis, alteração da função de ligação, alteração da família de distribuição.
- Resíduos utilizados nos MLGs: [Resíduo de Pearson](#) e [Resíduo da Deviance](#).



## Resíduo de Pearson

$$r_i = \frac{y_i - \hat{\mu}_i}{\sqrt{\hat{V}(Y_i)}}$$

- $\hat{\mu}_i$  é o valor esperado pela resposta para a observação  $i$ .
- $\hat{V}(Y_i)$  é a variância estimada da resposta.
- Aqui,  $X^2 = \sum_{i=1}^n r_i^2$ , que é a estatística de qui-quadrado de Pearson para bondade de ajuste.

## Resíduo da Deviance

$$d_i = \text{sign}(y_i - \hat{\mu}_i) \sqrt{2 \{ \ell(\hat{\mu}_{\max,i}; y_i) - \ell(\hat{\mu}_i; y_i) \}}$$

- $\ell(\mu_{\max,i}; y_i)$  é a log-verossimilhança do modelo maximal. Neste caso  $\hat{\mu}_{\max,i} = y_i$ .
- $\ell(\mu_i; y_i)$  é a log-verossimilhança da observação com parâmetro  $\mu_i$ .
- Origina-se da contribuição de cada ponto para a Deviance total do modelo, ou seja,  $D = \sum_{i=1}^n d_i^2$ .



- Os resíduos padronizados são definidos por:

$$s_i^* = \frac{r_i}{\sqrt{1 - h_{ii}}}$$

onde  $r_i$  é o resíduo para a observação  $i$  e  $h_{ii}$  mede o grau de influência da observação no ajuste do modelo (leverage) e é obtido por meio do  $i$ -ésimo elemento da diagonal da matriz hessiana  $\mathbf{H}$ .

- As análises de resíduos em MLG devem ser conduzidas de forma semelhante à dos modelos lineares normais.
- Vale lembrar que não há qualquer pressuposto sobre a distribuição dos resíduos. Neste caso, em um MLG não se deve avaliar normalidade dos resíduos.
- Se os dados são binários, por exemplo, ou se  $n_i$  é pequeno para a maioria dos níveis das covariáveis, haverá poucos valores distintos dos resíduos e os gráficos serão pouco informativos.
- Neste caso, será necessário confiar na estatística agregada da bondade de ajuste ( $X^2$  e  $D$ ) e em outros diagnósticos.



- Resíduo (Pearson/deviance) vs valor ajustado  $\hat{\mu}_i$ : verificar padrões (curvas, heterocedasticidade)
- QQ-plot dos resíduos (quando aplicável): procurar desvios sistemáticos.
- Resíduo vs preditor (covariáveis): detectar tendência não modelada. Se o modelo não é adequado, os pontos podem apresentar padrões de comportamento, sugerindo que termos adicionais devem ser incluídos.
- Distância de Cook (DFBetas, DFFits) e Leverage: localizar pontos influentes.



# Simulação de Dados para o Modelo Poisson

## Exercício

Considere um modelo de regressão de Poisson com preditores  $x_1$  e  $x_2$ . Simule um conjunto de dados com  $n = 100$  observações a partir do modelo:

$$\log(\mu_i) = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i},$$

com  $\beta_0 = 1$ ,  $\beta_1 = 0.3$  e  $\beta_2 = 0.1$ , onde:

- $x_1 \sim \mathcal{N}(2, 1)$ ;
- $x_2 \sim \mathcal{N}(1, 1)$ ;
- $y_i \sim \text{Poisson}(\mu_i)$ .

Gere os dados, ajuste um modelo de regressão de Poisson e realize a análise dos resíduos.



# Métodos de Regularização

- Os **métodos de regularização** são técnicas usadas em modelos de regressão e aprendizado de máquina para evitar **overfitting**.
- Na regressão usual de um modelo normal, ajustamos o modelo para **minimizar o erro quadrático**.
- **Problema**: Se o número de preditores  $p$  for grande, ou se houver multicolinearidade (preditores correlacionados), o estimador  $\hat{\beta}$  pode ter alta variância e ser instável.
- **Ideia da regularização**: introduzir informação extra ou uma restrição/ penalização sobre os coeficientes  $\beta$ , controlando seu tamanho ou complexidade, com objetivo de reduzir a variância do estimador, mesmo que isso introduza um pequeno viés.



# Métodos de Regularização

De forma geral, para lidar com esses problemas, o critério de MQO é modificado:

## Forma com restrição

$$\min_{\beta \in \mathbb{R}^p} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 \quad \text{sujeito a} \quad \beta \in C$$

onde  $C$  é um conjunto de restrições (tipicamente convexo).

## Forma Penalizada

$$\min_{\beta \in \mathbb{R}^p} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + P(\beta)$$

onde  $P(\cdot)$  é uma função de penalização (tipicamente convexa).

## Princípio Fundamental

A regularização nos permite navegar no trade-off entre viés e variância: introduzimos um pequeno viés para reduzir drasticamente a variância do estimador.





# Normas Canônicas e Penalização

Duas escolhas fundamentais para a penalização dão origem a métodos clássicos de regularização:

- Norma  $\ell_2$  (Ridge Regression): Penaliza a magnitude quadrada dos coeficientes:

$$P(\beta) = \lambda \|\beta\|_2^2 = \lambda \sum_{j=1}^p \beta_j^2$$

solução fechada, não produz esparsidade e reduz variância.

- Norma  $\ell_1$  (Lasso): Penaliza a magnitude absoluta dos coeficientes:

$$P(\beta) = \lambda \|\beta\|_1 = \lambda \sum_{j=1}^p |\beta_j|$$

convexa e esparsa; trade-off ótimo entre viés e variância.



# Propriedade 1: Esparsidade


## Definição (Esparsidade)

Um estimador  $\hat{\beta}$  é esparso se muitos de seus componentes são exatamente zero ( $\hat{\beta}_j = 0$ ). Isso implica uma seleção automática de variáveis.

- **Lasso ( $\ell_1$ ):** produz soluções esparsas. Quanto maior  $\lambda$ , maior a esparsidade. **Pode ser entendido, então, como um método de seleção de variáveis!**
- **Ridge Regression ( $\ell_2$ ):** não produz soluções esparsas. Tipicamente, todos os coeficientes são não nulos.



# Por que $\ell_1$ induz esparsidade e $\ell_2$ não?



- **Lasso ( $\ell_1$ ):**  $|\beta_1| + |\beta_2| \leq t$ . A bola  $\ell_1$  tem quinas afiadas alinhadas com os eixos coordenados, levando a soluções esparsas.
- **Ridge Regression ( $\ell_2$ ):**  $\beta_1^2 + \beta_2^2 \leq t$ . A bola  $\ell_2$  é suave, sem quinas, tornando improvável que os coeficientes sejam exatamente zero.



# Propriedade 2: Convexidade

## Definição (Problema de Otimização Convexa)

Um problema é convexo se a função objetivo e as restrições de desigualdade são funções convexas, e as restrições de igualdade são afins.

- Lasso ( $\ell_1$ ) e Ridge ( $\ell_2$ ): são problemas de otimização convexos.

## Por que a Convexidade é Importante?

- **Ótimo Global:** Qualquer mínimo local é também um mínimo global. Isso garante que o algoritmo converge para a melhor solução.
- **Eficiência Computacional:** Existem algoritmos muito eficientes e confiáveis para resolver problemas convexos.



# Convexidade e Regularização em MLG

- No MLG, a **log-verossimilhança**  $\ell(\beta)$  é **concava** em  $\beta$ .
- Portanto, o **negativo da log-verossimilhança**  $-\ell(\beta)$  é **convexo**.
- Maximizar  $\ell(\beta)$  é equivalente a minimizar  $-\ell(\beta)$ :

$$\hat{\beta} = \arg \min_{\beta} -\ell(\beta)$$

- Ao adicionarmos uma penalização convexa  $P(\beta)$ , obtemos:

$$\hat{\beta} = \arg \min_{\beta} -\ell(\beta) + \lambda P(\beta)$$

- Se  $P(\beta)$  é convexa (como  $\ell_1$  ou  $\ell_2$ ), o problema continua **convexo**.

## Vantagens da Convexidade

- **Ótimo global**: não há mínimos locais espúrios.
- **Métodos de regularização** (Lasso, Ridge, Elastic Net) aplicáveis de forma direta em MLG.



# Simulação de Dados para Regressão Logística

**Objetivo:** Simular um conjunto de dados para ilustrar modelos de regressão logística com múltiplos preditores, incluindo esparsidade (coeficientes nulos).

- Número de observações:  $n = 200$
- Número de preditores:  $p = 10$
- Matriz de preditores  $\mathbf{X}$  gerada de forma aleatória,  $X_{ij} \sim N(0, 1)$
- Vetor de coeficientes verdadeiros  $\beta = (2, -1.5, 0, 0, 1, 0, 0, 0.5, 0, 0)$
- Probabilidades verdadeiras calculadas pela função logística:

$$\pi_i = \frac{1}{1 + \exp(-\eta_i)}, \quad \eta_i = \mathbf{X}_i \beta$$

- Variável resposta binária  $y_i \sim \text{Bernoulli}(\pi_i)$
- Alguns coeficientes são zero para permitir avaliação de métodos de regularização (ex.: Lasso)

