



GET00211 - Modelos Lineares 2

Rafael Erbisti

Instituto de Matemática e Estatística
Universidade Federal Fluminense

Aula 13

- Se a variável resposta é categórica, com mais de duas categorias, então há duas abordagens de Modelos Lineares Generalizados.
- Uma é baseada na generalização dos modelos para dados com duas categorias para o caso de mais categorias (modelo politômico), aplicável a respostas nominais ou ordinais.
- Outra abordagem é modelar as frequências, ou contagens, para os diferentes níveis da covariável, como resposta de um modelo de Poisson (modelo log-linear).



Distribuição Multinomial

- Considere uma variável aleatória \mathbf{Y} com J categorias.
- Sejam $\pi_1, \pi_2, \dots, \pi_J$ as respectivas probabilidades, com

$$\pi_1 + \pi_2 + \dots + \pi_J = 1.$$

- Se há n observações independentes que resultam em y_1 para a categoria 1, y_2 para a categoria 2, e assim por diante, então seja

$$\mathbf{y} = (y_1, y_2, \dots, y_J)', \quad \text{com} \quad \sum_{j=1}^J y_j = n.$$



- A distribuição multinomial é dada por:

$$f(\mathbf{y}; n) = \frac{n!}{y_1! y_2! \dots y_J!} \pi_1^{y_1} \pi_2^{y_2} \dots \pi_J^{y_J} \quad (1)$$

- Se $J = 2$, então $\pi_2 = 1 - \pi_1$ e $y_2 = n - y_1$, e vemos que a distribuição binomial é um caso particular da distribuição multinomial.
- Em geral, a distribuição multinomial não satisfaz os pré-requisitos para ser um membro da família exponencial.



Distribuição Multinomial

- Entretanto, a relação a seguir com a distribuição de Poisson garante que o uso de MLG é adequado.
- Sejam Y_1, \dots, Y_J variáveis aleatórias independentes com

$$Y_j \sim \text{Poisson}(\lambda_j).$$

- A função de probabilidade conjunta é:

$$f(\mathbf{y}) = \prod_{j=1}^J \frac{\lambda_j^{y_j} e^{-\lambda_j}}{y_j!}.$$

- Seja $n = Y_1 + Y_2 + \dots + Y_J$. Então n é uma variável aleatória com distribuição:

$$n \sim \text{Poisson}(\lambda_1 + \lambda_2 + \dots + \lambda_J).$$



Distribuição Multinomial

- Observe que o valor de n é completamente determinado pelos valores de $\mathbf{y} = (y_1, \dots, y_J)$.
- Assim, o evento $(\mathbf{Y} = \mathbf{y}, N = n)$ só tem probabilidade não nula se

$$n = \sum_{j=1}^J y_j.$$

- Portanto, a conjunta é essencialmente a mesma função de probabilidade:

$$f(\mathbf{y}, n) = f(\mathbf{y}) \quad \text{para } n = \sum_j y_j.$$

- Isso permite escrever a condicional como:

$$f(\mathbf{y} \mid n) = \frac{f(\mathbf{y})}{f(n)}$$



Distribuição Multinomial

- Portanto, a distribuição condicional de \mathbf{y} dado n é:

$$f(\mathbf{y} \mid n) = \frac{\prod_{j=1}^J \frac{\lambda_j^{y_j} e^{-\lambda_j}}{y_j!}}{\frac{(\lambda_1 + \dots + \lambda_J)^n e^{-(\lambda_1 + \dots + \lambda_J)}}{n!}}$$

- A expressão anterior pode ser simplificada para:

$$f(\mathbf{y} \mid n) = \frac{n!}{y_1! \dots y_J!} \left(\frac{\lambda_1}{\sum_{k=1}^J \lambda_k} \right)^{y_1} \dots \left(\frac{\lambda_J}{\sum_{k=1}^J \lambda_k} \right)^{y_J} \quad (2)$$

- Logo, $\mathbf{Y} \mid n \sim \text{Multinomial}(n, \pi_1, \dots, \pi_J)$, com

$$\pi_j = \frac{\lambda_j}{\sum_{k=1}^J \lambda_k}$$



Distribuição Multinomial

- Se $\pi_j = \frac{\lambda_j}{\sum_{k=1}^J \lambda_k}$ para $j = 1, \dots, J$, então a equação (1) é a mesma que a equação (2), e

$$\sum_{j=1}^J \pi_j = 1$$

- Portanto, a distribuição multinomial pode ser assumida como a distribuição conjunta de variáveis de Poisson, **condicional ao fato de que sua soma seja n** .
- Para a distribuição multinomial, pode-se mostrar que:

$$E(Y_j) = n\pi_j \quad V(Y_j) = n\pi_j(1 - \pi_j) \quad \text{Cov}(Y_j, Y_k) = -n\pi_j\pi_k$$



Regressão Logística Nominal

- A regressão logística nominal é utilizada quando **não há qualquer ordem natural** entre as categorias da variável resposta.
- Uma categoria é arbitrariamente escolhida como a **categoria de referência**.
- Suponha que a referência seja a primeira categoria. Então, os logits para as outras categorias são definidos como:

$$\text{logit}(\pi_j) = \log\left(\frac{\pi_j}{\pi_1}\right) = \mathbf{x}_j' \boldsymbol{\beta}_j, \quad j = 2, \dots, J. \quad (3)$$



- As $(J - 1)$ equações de logito são usadas simultaneamente para estimar os parâmetros β_j .
- Uma vez obtidas as estimativas $\hat{\beta}_j$, os preditores lineares

$$\mathbf{x}'_j \hat{\beta}_j$$

podem ser calculados.

- Da equação anterior, temos:

$$\hat{\pi}_j = \hat{\pi}_1 \exp \left(\mathbf{x}'_j \hat{\beta}_j \right), \quad j = 2, \dots, J.$$



- Como $\hat{\pi}_1 + \hat{\pi}_2 + \dots + \hat{\pi}_J = 1$, temos:

$$\hat{\pi}_1 = \frac{1}{1 + \sum_{j=2}^J \exp(\mathbf{x}'_j \hat{\beta}_j)}$$

- E, para $j = 2, \dots, J$,

$$\hat{\pi}_j = \frac{\exp(\mathbf{x}'_j \hat{\beta}_j)}{1 + \sum_{k=2}^J \exp(\mathbf{x}'_k \hat{\beta}_k)}$$



- Os resíduos do qui-quadrado de Pearson são dados por:

$$r_i = \frac{o_i - e_i}{\sqrt{e_i}},$$

onde o_i e e_i são, respectivamente, as frequências observadas e esperadas, para $i = 1, \dots, N$, sendo N igual a J vezes o número de padrões distintos da covariável.

- Os resíduos podem ser utilizados para verificar a bondade de ajuste do modelo.
- As estatísticas para avaliação da bondade de ajuste são **análogas às da regressão logística binomial**.



- Estatística Qui-quadrado de Pearson:

$$\chi^2 = \sum_{i=1}^N r_i^2,$$

onde $r_i = \frac{o_i - e_i}{\sqrt{e_i}}$ são os resíduos de Pearson.

- Deviance**: definida em termos dos valores máximos da log-verossimilhança do modelo ajustado ($\hat{\beta}$) e do modelo saturado ($\hat{\beta}_{\max}$):

$$D = 2 \left[\ell(\hat{\beta}_{\max}) - \ell(\hat{\beta}) \right]$$

- Se o modelo se ajusta bem, então χ^2 e D seguem, assintoticamente, uma distribuição qui-quadrado χ^2_{N-p} , onde p é o número de parâmetros estimados.



- Usualmente, é mais fácil interpretar os efeitos das variáveis explicativas em termos das **razões de chances** (odds ratios) do que diretamente pelos parâmetros β .
- Considere uma variável resposta com J categorias e uma variável explicativa x , que indica se o fator está **presente** ($x = 1$) ou **ausente** ($x = 0$).
- As razões de chances para a resposta j ($j = 2, \dots, J$) em relação à categoria de referência ($j = 1$) são dadas por:

$$OR_j = \psi_j = \frac{\pi_j^{(p)}}{\pi_1^{(p)}} \bigg/ \frac{\pi_j^{(a)}}{\pi_1^{(a)}}$$

onde $\pi_j^{(p)}$ e $\pi_j^{(a)}$ denotam, respectivamente, as probabilidades da categoria j quando o fator está presente ou ausente.



- Para o modelo:

$$\log \left(\frac{\pi_j}{\pi_1} \right) = \beta_{0j} + \beta_{1j}x, \quad j = 2, \dots, J,$$

as chances são dadas por:

- 1 Quando o fator está **ausente** ($x = 0$):

$$\frac{\pi_j^{(a)}}{\pi_1^{(a)}} = \exp(\beta_{0j}),$$

- 2 Quando o fator está **presente** ($x = 1$):

$$\frac{\pi_j^{(p)}}{\pi_1^{(p)}} = \exp(\beta_{0j} + \beta_{1j}).$$



- Portanto, a razão de chances pode ser escrita como:

$$OR_j = \exp(\beta_{1j}),$$

que é estimado por:

$$\widehat{OR}_j = \exp(\hat{\beta}_{1j}).$$

- Se $\beta_{1j} = 0$, então $OR_j = 1$, o que corresponde a um “não efeito” da presença do fator sobre a categoria j em relação à categoria de referência.



- Por exemplo, intervalos de 95% de confiança para OR_j são calculados como:

$$\exp \left(\hat{\beta}_{1j} \pm 1,96 \times \text{s.e.}(\hat{\beta}_{1j}) \right),$$

onde $\text{s.e.}(\hat{\beta}_{1j})$ é o erro padrão da estimativa $\hat{\beta}_{1j}$.

- Intervalos de confiança que **não incluem o valor unitário** indicam que o parâmetro β_{1j} é significativamente diferente de zero, ou seja, há efeito da variável explicativa sobre a categoria j em relação à referência.
- Para a regressão logística nominal, as variáveis explicativas podem ser categóricas ou contínuas.
- A escolha da categoria de referência para a variável resposta afeta as estimativas dos parâmetros $\hat{\beta}$.
- Mas não afeta as estimativas das probabilidades ajustadas $\hat{\pi}_j$ nem os valores ajustados do modelo.



Exemplo

- Num estudo sobre veículos, homens e mulheres que dirigiam carros grandes, médios e pequenos foram entrevistados sobre suas preferências a respeito de carros.
- A amostra compreendeu 50 indivíduos em cada uma das 6 categorias (masculino/feminino e 3 faixas de idade).
- Pediu-se que eles ordenassem algumas características consideradas na compra de seus carros.
- A tabela a seguir apresenta as proporções observadas segundo o nível de importância dos itens ar condicionado e direção hidráulica, de acordo com o sexo e a idade do indivíduo.
- As categorias de resposta são: “*sem importância*”, “*importante*” ou “*muito importante*”.



Exemplo

Sexo	Idade	Resposta			Total
		Sem importância	Importante	Muito importante	
Mulheres	18–23	26 (58%)	12 (27%)	7 (16%)	45
	24–40	9 (20%)	21 (47%)	15 (33%)	45
	> 40	5 (8%)	14 (23%)	41 (68%)	60
Homens	18–23	40 (62%)	17 (26%)	8 (12%)	65
	24–40	17 (39%)	15 (34%)	12 (27%)	44
	> 40	8 (20%)	15 (37%)	18 (44%)	41
Total		105	94	101	300



Exemplo

- Escolhemos a categoria “sem importância” como a categoria de base.
- A tabela a seguir mostra o resultado para um modelo de regressão logística, assumindo como categoria de referência a resposta “sem importância” e o grupo de idade 18–23 anos.

$$\log \left(\frac{\pi_j}{\pi_1} \right) = \beta_{0j} + \beta_{1j}x_1 + \beta_{2j}x_2 + \beta_{3j}x_3, \quad j = 2, 3$$

Codificação das variáveis explicativas

$$x_1 = \begin{cases} 1, & \text{se homem} \\ 0, & \text{se mulher} \end{cases} \quad x_2 = \begin{cases} 1, & \text{se idade entre 24 e 40 anos} \\ 0, & \text{caso contrário} \end{cases}$$

$$x_3 = \begin{cases} 1, & \text{se idade maior que 40 anos} \\ 0, & \text{caso contrário} \end{cases}$$



Parâmetro β	Estimativa b (erro padrão)	Razão de chances, $OR =$ (intervalo de confiança de 95 %)	
$\log (\pi_2 / \pi_1)$: importante vs. sem importância			
β_{02} : constante	-0,591 (0,284)		
β_{12} : homens	-0,388 (0,301)	0,68	(0,38, 1,22)
β_{22} : 24-40	1,128 (0,342)	3,09	(1,58, 6,04)
β_{32} : > 40	1,588 (0,403)	4,89	(2,22, 10,78)
$\log (\pi_3 / \pi_1)$: muito importante vs. sem importância			
β_{03} : constante	-1,039 (0,331)		
β_{13} : homens	-0,813 (0,321)	0,44	(0,24, 0,83)
β_{23} : 24-40	1,478 (0,401)	4,38	(2,00, 9,62)
β_{33} : > 40	2,917 (0,423)	18,48	(8,07, 42,34)

Figura: Ajuste do modelo Multinomial.



Exemplo

- $\ell(\hat{\beta}_{\text{nulo}}; y) = -329,27$ (modelo contendo apenas β_{02} e β_{03})
- $\ell(\hat{\beta}; y) = -290,35,$
- $\text{Pseudo-}R^2 = \frac{(-329,27 + 290,35)}{-329,27} = 0,118$
- $AIC = -2(-290,35) + 16 = 596,7$
- Pelas estimativas, intervalos de confiança e razões de chances (*OR*), observa-se que a importância do ar-condicionado e da direção hidráulica cresce significativamente com a idade.
- Aparentemente, homens consideram essas características menos importantes.



Exemplo

- Para estimar as probabilidades $\hat{\pi}_1$, $\hat{\pi}_2$ e $\hat{\pi}_3$, consideramos o grupo de **mulheres** ($x_1 = 0$) e faixa etária **18–23 anos** ($x_2 = 0$, $x_3 = 0$).
- Para esse grupo:

$$\log\left(\frac{\hat{\pi}_2}{\hat{\pi}_1}\right) = -0,591 \quad \text{e} \quad \log\left(\frac{\hat{\pi}_3}{\hat{\pi}_1}\right) = -1,039$$

- Além disso, sabemos que:

$$\hat{\pi}_1 + \hat{\pi}_2 + \hat{\pi}_3 = 1$$

- Portanto:

$$\hat{\pi}_1 = \frac{1}{1 + e^{-0,591} + e^{-1,039}} = 0,524, \quad \hat{\pi}_2 = 0,290, \quad \hat{\pi}_3 = 0,186$$



Exemplo

- Agora, considere **homens** ($x_1 = 1$) com **idade acima de 40 anos** ($x_2 = 0$, $x_3 = 1$).
- Nesse caso:

$$\log\left(\frac{\hat{\pi}_2}{\hat{\pi}_1}\right) = -0,591 - 0,388 + 1,588 = 0,609$$

$$\log\left(\frac{\hat{\pi}_3}{\hat{\pi}_1}\right) = -1,039 - 0,813 + 2,917 = 1,065$$

- Sabendo que $\hat{\pi}_1 + \hat{\pi}_2 + \hat{\pi}_3 = 1$, temos:

$$\hat{\pi}_1 = \frac{1}{1 + e^{0,609} + e^{1,065}} = 0,174, \quad \hat{\pi}_2 = 0,320, \quad \hat{\pi}_3 = 0,505$$



Exemplo: Modelo completo com interações

- O modelo completo ajustado inclui termos para **idade**, **sexo** e as **interações entre sexo e idade**.
- Ele possui 6 parâmetros para $j = 2$ (um intercepto, coeficientes para sexo, duas categorias de idade e duas interações sexo \times idade) e mais 6 parâmetros para $j = 3$, resultando em um total de **12 parâmetros**.
- Aqui, $\ell(\hat{\beta}_{\max}; y) = -288,38$ e, portanto,

$$D = 2(-288,38 + 290,35) = 3,94$$

- Os graus de liberdade associados a essa deviance são: $gl = 12 - 8 = 4$.
- Como esperado, os valores das estatísticas de bondade de ajuste ($D = 3,94$ e $X^2 = 3,93$) são muito similares.
- Quando comparadas ao quantil da distribuição $\chi^2_{(4)}$, elas sugerem que o modelo ajustado fornece uma boa descrição dos dados.

